RAG e engenharia de contexto

Como encontrar a informação certa, organizar o contexto e orientar a resposta de um LLM.

BUSCA + ORGANIZAÇÃO + RESPOSTA



Engenharia de contexto

É a construção estratégica do conjunto de informações que acompanha o pedido enviado ao LLM.

Imagine uma pessoa nova na equipe

Para realizar bem uma tarefa, ela precisa conhecer as regras, ver um exemplo, consultar o histórico e saber quais ferramentas pode usar. Com um LLM, a lógica é parecida: a resposta depende do que foi incluído no contexto.

O contexto complementa o que o modelo aprendeu no treinamento.

Quatro partes do contexto

01

Instruções

Regras, tom de voz, persona e limites de segurança.

02

Exemplos

Uma amostra do formato ou estilo esperado.

03

Dados relevantes

Histórico, informações do usuário ou documentos externos.

04

Ferramentas

Funções e APIs disponíveis para resolver a tarefa.

Objetivo: incluir o que é necessário para orientar a resposta.

Por que usar RAG?

Um LLM pode não conhecer dados recentes ou documentos privados. Sem boas referências, também pode gerar respostas que parecem verdadeiras, mas estão erradas.

Informação desatualizada	O modelo pode não conhecer mudanças posteriores ao treinamento.
Dados privados	Documentos internos não fazem parte do conhecimento geral do modelo.
Respostas sem base	Sem evidências relevantes, uma resposta plausível pode estar incorreta.

Analogia: numa prova com consulta, o RAG entrega o livro certo antes da resposta.

Como funciona o RAG

1

Preparação dos documentos

Documentos são divididos em blocos menores. Cada bloco vira um embedding e é guardado em um banco vetorial.

2

Busca dos trechos

A pergunta também vira um vetor. A busca semântica encontra blocos relacionados ao assunto.

3

Geração da resposta

Pergunta e trechos relevantes são reunidos no contexto que o LLM recebe para responder.

PDFs, páginas e outros documentos → blocos + embeddings → busca semântica → resposta

RAG e engenharia de contexto

Cada um cumpre uma função diferente no caminho até a resposta.

RAG

Encontra e recupera

Busca os documentos e trechos mais relevantes na base de dados.

ENGENHARIA DE CONTEXTO

Organiza a informação

Estrutura instruções, documentos recuperados e pergunta no prompt final.

O RAG busca; a engenharia de contexto monta o material que chega ao modelo.

Fluxo completo: da pergunta à resposta

01

Pergunta

O usuário descreve o que precisa.

02

RAG

Localiza trechos relevantes nos documentos.

03

Contexto

Combina instruções, trechos e pergunta.

04

LLM

Produz uma resposta apoiada no contexto.

Pergunta + evidências relevantes + instruções claras

O que o RAG pode melhorar

01	**Respostas ligadas a fontes**	O modelo recebe trechos de referência para embasar a resposta.
02	**Uso de dados privados**	A base pode fornecer documentos internos sem incorporá-los ao treinamento do modelo.
03	**Conteúdo mais atual**	Atualizar os documentos indexados permite buscar informações novas.

Resposta melhor orientada depende de bons documentos e de um contexto bem montado.