Como funcionam os LLMs

Uma explicação visual sobre linguagem, contexto, treinamento e aplicações

Large Language Models

O que é um LLM?

Um modelo de inteligência artificial treinado para compreender e produzir linguagem.

“Grande” descreve duas escalas:

Parâmetros
Bilhões de valores ajustáveis que influenciam como o modelo processa texto.

Dados
Coleções extensas de livros, artigos, código e páginas da web.



A ideia central: prever o próximo token

O modelo recebe um prompt e calcula quais fragmentos poderiam vir em seguida.

A previsão considera o contexto e os padrões aprendidos no treinamento.

Exemplo

“Hoje o céu está...”

Uma continuação possível: “ensolarado”.



Do texto aos números: tokens e embeddings

O texto é dividido em unidades menores. Cada token recebe um ID e vira um vetor numérico.

Esses vetores ajudam o modelo a representar relações entre termos.

Frase → tokens → IDs → vetores

Termos usados em contextos parecidos tendem a ficar próximos no espaço semântico.

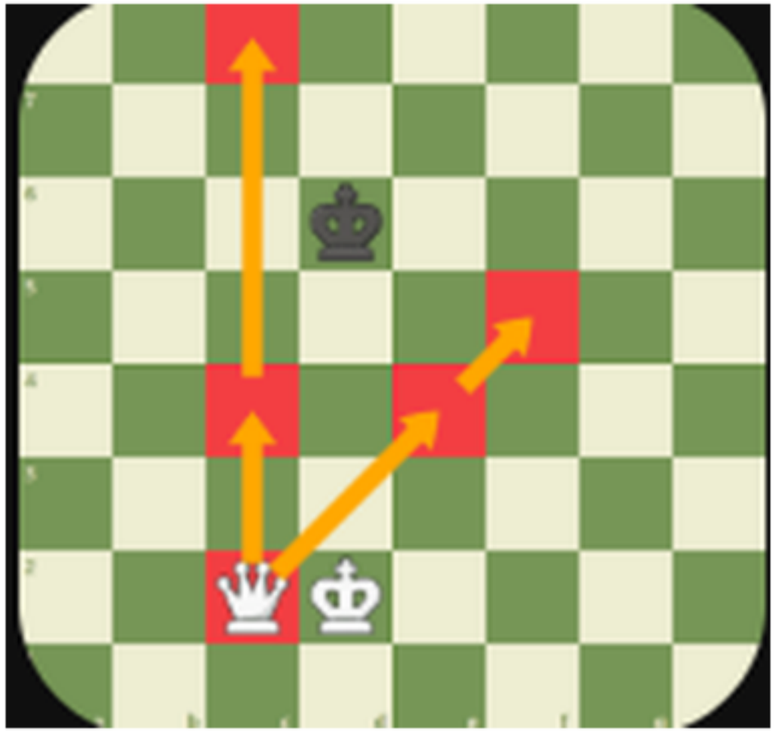


Uma analogia para embeddings

“Rei” e “rainha” têm significados relacionados, por isso suas representações podem ficar próximas no espaço vetorial.

No tabuleiro, as peças também ocupam casas vizinhas.

Proximidade representa semelhança de contexto e significado.



Atenção: o contexto muda o sentido

O Transformer relaciona palavras da frase para entender quais pistas importam em cada trecho.



Uma palavra, sentidos diferentes

O contexto da frase ajuda a identificar de qual personagem se está falando.



A Origem dos Guardiões



Sonho / The Sandman



Homem-Areia

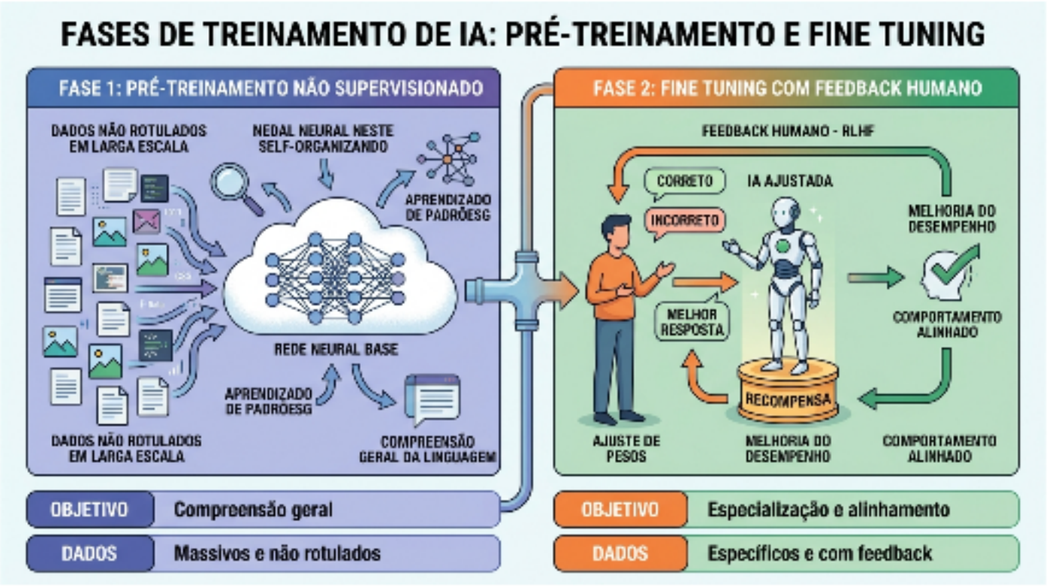
Como o modelo aprende

1 Pré-treinamento

O modelo pratica prever o próximo token em grandes coleções de texto e aprende padrões de linguagem.

2 Ajuste e alinhamento

Exemplos e feedback humano orientam o modelo a responder de forma mais útil e a seguir instruções.



Onde os LLMs são usados

01	**Escrita e tradução**	Redigir, revisar, adaptar tom e traduzir textos.
02	**Leitura e síntese**	Resumir relatórios e localizar informações importantes.
03	**Programação**	Gerar, explicar, documentar e revisar código.
04	**Atendimento**	Responder com apoio de bases de conhecimento.
05	**Agentes**	Planejar tarefas e usar ferramentas para concluí-las.

Em resumo: texto → tokens → contexto → resposta provável